Clasificación automática de tickets de mantenimiento

Archivo: *Clasificacion de Tickets 2021.xlsm* (hoja **Data**) | Entrada: columna Q *Work Description (Close Details)* | Salida: columna AB *Dispositivo*

1. Objetivo

Construir un algoritmo que, dado el texto libre con el que el técnico cierra un ticket (columna Q), prediga la categoría **Dispositivo** (columna AB) asignada manualmente. Esto permitiría automatizar la clasificación de tickets nuevos y reducir el trabajo manual.

2. Procesamiento de datos

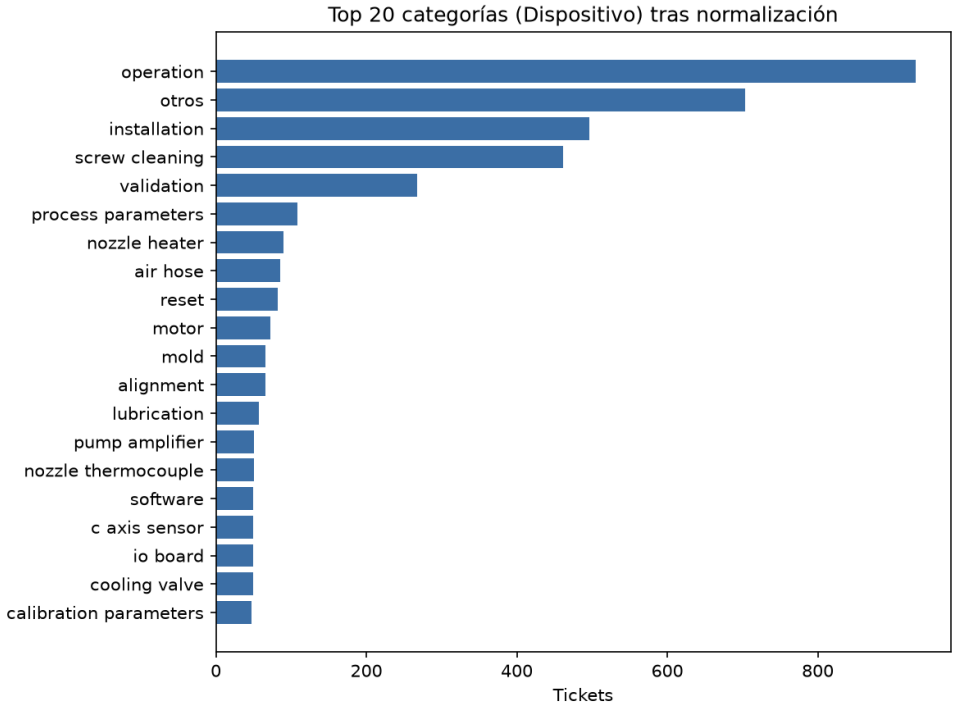
La hoja contiene 11,150 filas; 8,599 tienen texto en Q y 6,220 tienen categoría en AB. Sólo **5,222** filas tienen ambas y constituyen el conjunto supervisado. Pasos aplicados:

• **Normalización de etiquetas:** minúsculas, espacios y corrección de typos/sinónimos (p.ej. *Door´s switch* / *door's swtch* → *door's switch*; *bus can alarm* → *buscan error*). Las clases pasaron de 519 a 353.

• **Limpieza de texto:** minúsculas, eliminación de acentos y signos, sustitución de números por *num* y de referencias a tickets (REQ-xxxx) por *ticketref*, eliminación de stopwords en español.

• **Agrupación de clases raras:** las categorías con menos de 10 ejemplos se agruparon en *otros* (13.5% de los datos), dejando **87 clases**.

• **División:** 80/20 estratificada (4,177 entrenamiento, 1,045 prueba) + validación cruzada 5-fold.



La distribución está muy desbalanceada: *operation*, *installation*, *screw cleaning* y *validation* concentran cerca del 45% de los tickets, mientras que la mayoría de las clases tienen decenas de ejemplos.

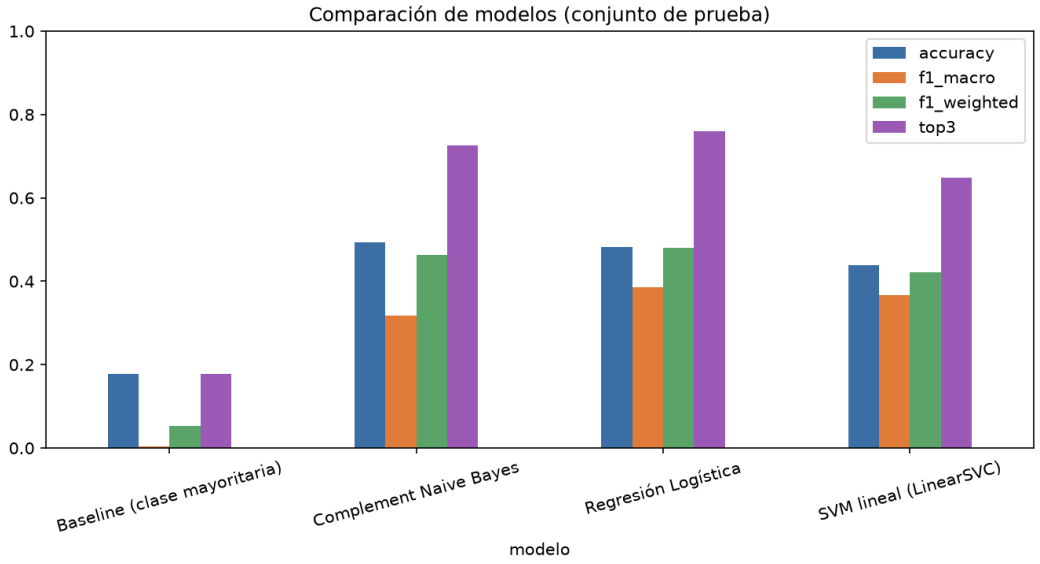
3. Algoritmo

Representación: TF-IDF combinando (a) n-gramas de palabras (1-2) y (b) n-gramas de caracteres (3-5). Los n-gramas de caracteres hacen al modelo robusto a faltas de ortografía y a la mezcla español/inglés típica de los técnicos (*termopar*, *thermocouple*, *husillo*…).

Clasificadores comparados: baseline de clase mayoritaria, Complement Naive Bayes, Regresión Logística (con *class_weight='balanced'* para mitigar el desbalance) y SVM lineal. Se eligió el modelo con mayor F1 ponderado en el conjunto de prueba; además del acierto exacto se mide **top-3** (la categoría correcta está entre las 3 sugerencias más probables), útil para un esquema de sugerencia asistida.

4. Resultados

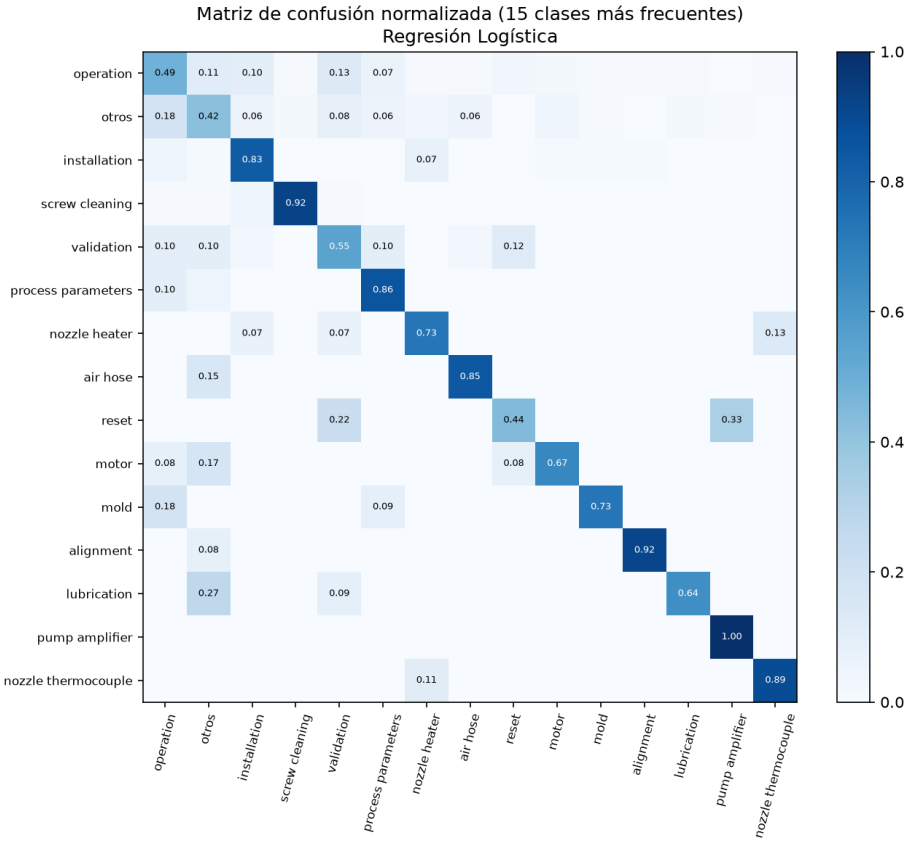
Modelo	Accuracy	F1 macro	F1 ponderado	Top-3
Baseline (clase mayoritaria)	0.178	0.003	0.054	0.178
Complement Naive Bayes	0.493	0.318	0.463	0.726
Regresión Logística	0.482	0.386	0.480	0.760
SVM lineal (LinearSVC)	0.438	0.367	0.422	0.648



El mejor modelo es **Regresión Logística**: accuracy 48.2%, F1 ponderado 0.480 y **top-3 de 76.0%**, frente a 17.8% del baseline (≈2.7× mejor). La validación cruzada 5-fold da 49.6% ± 0.5%, confirmando que el resultado es estable.

Desempeño por categoría (15 más frecuentes)

Categoría	Precisión	Recall	F1	Soporte
operation	0.56	0.32	0.41	186
otros	0.39	0.26	0.31	141
installation	0.68	0.70	0.69	99
screw cleaning	0.95	0.89	0.92	93
validation	0.40	0.43	0.41	54
process parameters	0.41	0.82	0.55	22
nozzle heater	0.44	0.61	0.51	18
air hose	0.52	0.65	0.58	17
reset	0.22	0.24	0.23	17
motor	0.44	0.53	0.48	15
mold	0.57	0.62	0.59	13
alignment	0.85	0.85	0.85	13
lubrication	0.58	0.58	0.58	12
pump amplifier	0.53	0.80	0.64	10
nozzle thermocouple	0.67	0.80	0.73	10



Las categorías con vocabulario específico se clasifican muy bien (*screw cleaning* F1 0.92, *alignment* 0.85, *nozzle thermocouple* 0.73). Las mayores confusiones ocurren entre categorías genéricas (*operation*,

validation, *reset*, *otros*), cuyos textos suelen ser "se realizan pruebas y opera correctamente", sin mencionar el componente intervenido.

Ejemplos de predicción

Texto de entrada (col. Q)	Categoría predicha
se realiza limpieza de husillo con purga	screw cleaning
se cambia termopar de nariz	nozzle thermocouple
se reemplaza manguera de aire dañada	air hose
se realizan pruebas funcionales y opera correctamente	vacuum valve
se cambia resistencia de nariz	nozzle heater
se reinicia equipo por error de comunicacion can	can communication

5. Conclusiones y siguientes pasos

• Se cuenta con un clasificador funcional (*clasificador_tickets.py*, modelo en *modelo_tickets.pkl*, función *predecir(textos)*) que acierta ~50% en exacto y ~76% en top-3 sobre 87 clases.

• La principal limitación está en los datos: etiquetas inconsistentes (519 variantes originales), muchas clases con pocos ejemplos y textos que no describen el componente.

• Siguientes pasos: (1) depurar el catálogo de *Dispositivo* con el usuario de negocio usando la hoja *Catalogo*; (2) clasificación jerárquica usando *Sub Sistema* → *Dispositivo*; (3) añadir como variables la columna *Description* (problema reportado) y el tipo de equipo; (4) probar embeddings multilingües / modelos tipo BERT; (5) usarlo como sistema de sugerencia top-3.